

基于特征点检测的生猪行为识别方法

倪鹏飞¹, 周素茵¹, 叶俊华², 徐爱俊^{1,3*}

(1. 浙江农林大学数学与计算机科学学院, 杭州 311300; 2. 浙江农林大学环境与资源学院, 杭州 311300;
3. 全省农业智能感知与机器人重点实验室, 杭州 311300)

摘要: 生猪行为与其健康状况密切相关, 生猪日常活动时的身体特征信息反映了其行为状态, 在生猪特征的提取过程中, 由于生猪姿态多变, 导致现有的生猪特征提取方法复杂且效率低, 从而影响了识别的效果。为此, 该研究构建了生猪特征点检测模型 YOLO-ASF-P2 以提取生猪关键部位的特征点时序信息, 再结合特征点的时序信息进而构建了生猪行为识别模型 CNN-BiGRU 识别生猪的坐、站和躺 3 种行为。YOLO-ASF-P2 以 YOLOv8s-Pose 为基线模型, 结合其骨干网络中 P2 层的大分辨率特征图充分挖掘更多目标特征, 同时采用 ASF 架构改进了其特征融合部分。首先, 应用尺度特征融合模块 SSFF 对齐不同尺度特征图, 提升了模型对多尺度特征信息的融合能力; 其次, 应用三重特征编码模块 TFE, 均衡多尺度特征信息的细节, 避免模型丢失目标特征; 最后, 通过通道和位置注意力机制 CPAM 捕获特征点的空间信息, 精准检测生猪的特征点。CNN-BiGRU 通过双向门控循环单元和注意力机制灵活捕捉生猪特征点时序信息并进行加权处理, 有效结合生猪特征点的时序特征, 高效识别生猪的行为。经验证, YOLO-ASF-P2 的检测精度为 92.5%, 召回率为 90.0%, 平均精度 ($AP_{50\sim95}$) 为 68.2%, 浮点运算次数为 39.6 G, 模型参数量为 18.4 M。CNN-BiGRU 模型针对生猪的坐、站和躺 3 种行为的平均识别精度为 95.8%, 浮点运算次数为 27.1 G, 模型参数量为 0.151 M。综上, 该研究提出的生猪特征点检测模型精度较高且轻量化, 能够有效应对生猪姿态多变对特征点准确检测的挑战。同时, 生猪行为识别模型结合生猪特征点时间域信息能有效识别生猪的坐、站和躺 3 种行为, 为生猪的行为识别提供了新思路。

关键词: 特征点检测; 生猪行为; 深度学习; 时间序列; YOLOv8sPose; BiGRU

doi: 10.11975/j.issn.1002-6819.202408188

中图分类号: TP391.4; S828

文献标志码: A

文章编号: 1002-6819(2025)-06-0173-12

倪鹏飞, 周素茵, 叶俊华, 等. 基于特征点检测的生猪行为识别方法[J]. 农业工程学报, 2025, 41(6): 173-184. doi: 10.11975/j.issn.1002-6819.202408188 <http://www.tcsae.org>
NI Pengfei, ZHOU Suyin, YE Junhua, et al. Recognizing pig behavior using feature point detection[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2025, 41(6): 173-184. (in Chinese with English abstract) doi: 10.11975/j.issn.1002-6819.202408188 <http://www.tcsae.org>

0 引言

当今养猪业正向着集约化和智能化方向转变^[1]。生猪行为能反映其健康和福利, 通过监测和分析生猪行为, 可以及时发现疾病及其他异常情况, 从而采取相应措施, 以提高猪群的健康水平和生产效率^[2]。传统的人工监测生猪行为的方法既耗时耗力又易受到人为主观因素的影响。利用机器视觉和深度学习技术监测与分析生猪行为既能提供大量实时和准确的生猪信息, 又能保护生猪的福利, 为保障生猪健康和提升养殖效率提供了有力支持^[3-4]。

近年来, 国内外学者基于机器视觉和深度学习技术对人和动物的检测与行为识别进行了大量研究^[5-7]。其中, 一部分研究集中于空间域, 通过分析图像中研究对象的像素与其周围环境的像素之间的关系进而分析其行为。在人体检测和姿态识别等研究方面, 苑朝等^[8]针对低光

照环境下行人检测精度低和模型参数量大的问题, 基于 YOLOv4 提出一种轻量化的多模态行人检测算法, 对于不同光照条件下行人目标的检测精度均超过 90%。傅裕等^[9]针对现有人体姿态估计模型计算量大和检测速度慢等问题, 通过引入轻量化模块、Non-Local 注意力机制和加权双向特征金字塔网络, 提出了一种基于 YOLOv8s-Pose 模型的轻量化改进算法, 改进后模型的参数量降低了 9.3%, 在人体关键点数据集 COCO 上的识别精度为 86.6%。徐红梅等^[10]为避免农田复杂作业环境下因拖拉机驾驶员的关键点被漏检而导致其行为识别和状态监测异常的问题, 提出了一种基于改进 YOLO-Pose 的驾驶员关键点检测算法, 改进算法的 mAP_{50} 和 $mAP_{50\sim95}$ 比基线模型分别提高了 4.24 和 4.15 个百分点。FANG 等^[11]采用对称积分关键点回归和特征引导的建议生成方法提出了 AlphaPose 算法, 实现了人体全身姿态的估计与追踪, 在 Halpe-FullBody 数据集上, 身体、面部和手部的检测精度分别为 67.8%、53.7% 和 22.6%。在生猪检测与行为识别等研究方面, 王鲁等^[12]以 Cascade Mask R-CNN 作为基准网络, 结合 HrNetV2 和 FPN 模块构建了猪体检测与分割模型, 在生猪的跪立、站立、躺卧和坐立 4 种行

收稿日期: 2024-08-26 修订日期: 2024-12-02

基金项目: 浙江省“领雁”研发攻关计划项目 (2022C02050)

作者简介: 倪鹏飞, 研究方向为农业信息化。Email: 1356589606@qq.com

※通信作者: 徐爱俊, 博士, 教授, 博士生导师, 研究方向为计算机视觉和 GIS 在农业中的应用。Email: xuaj1976@163.com

为上的识别准确率均超过 95%。SHAO 等^[13]使用深度可分离卷积网络在生猪的站、趴、侧躺和探索 4 种行为上的分类准确率为 92.45%。NASIRAHMADI 等^[14]结合基于区域的全卷积网络和残差网络提出 R-FCN ResNet101 方法在生猪的站、侧卧和俯卧 3 种行为上的识别平均精度均超过 92%。李丹等^[15]针对猪只爬跨行为自动化检测程度较低的问题,提出了一种基于 Mask R-CNN 的猪只爬跨行为识别算法,识别准确率为 94.5%。YANG 等^[16]首先使用 Faster R-CNN 算法识别生猪的头部,然后将头部与身体相关联,实现了生猪进食行为的识别,准确率达到 99.6%。关于人和动物的检测与行为识别的另一部分研究则考虑了时间域,结合研究对象的时序特征分析其行为,从而揭示行为在时空维度上的变化规律^[17]。在人的行为识别研究方面,姚砺等^[18]在 ST-GCN 的基础上增加多目标跟踪模块提取人体时序特征信息,构建暴力行为识别模型,在暴力行为检测视频数据集 RWF-2000 上的识别准确率达到 87.75%。李朝等^[19]提出基于人体特征点提取和多维时间序列分类的驾驶员行为识别方法,使用 YOLOv8 和人体姿态估计器蒸馏跟踪驾驶员区域并提取驾驶员的人体特征点矩阵,同时建立了基于时序信息的机器学习模型,模型在白天、夜晚以及国外研究人员构建的驾驶行为图像数据集上的测试准确率分别为 90.82%、88.77% 和 80.67%。在生猪行为识别研究方面,董力中等^[20]构建了基于 YOLOv5s 的猪只检测模型、基于轻量化 OpenPose 算法的猪只姿态估计模型和基于 ST-GCN 算法的猪只行为识别模型,并在时空图模型中应用了图卷积神经网络,构建了猪只行为识别系统,实现了生猪的站、走和躺 3 种行为的识别,平均识别准确率为 86.67%。WANG 等^[21]通过将深度学习和主成分分析法相结合,对视频中母猪的趴卧、侧卧、坐、站和走 5 种行为进行分类,在不包括和包括仔猪视频中的行为分类准确率分别为 95.33% 和 92.67%。YANG 等^[22]提出一种基于视频时空特征分析的猪爬跨行为识别算法,基于 Faster R-CNN 构建生猪检测器,研究相邻帧中与生猪爬跨行为相关的空间特征的变化,最后基于 XGBoost 构建的分类器识别生猪的爬跨行为,平均准确率为 95.15%,但当生猪行为变化频繁时,识别准确率较低。LIU 等^[23]首先采用 Resnet-50 结构的 SSD 目标检测算法跨帧关联生猪的检测框,并追踪生猪,通过提取生猪的时序特征,对其行为进行分类,实现了群养猪咬尾行为的识别,精度为 89.23%。ZHANG 等^[24]提出基于 Transformer 的时序神经网络,对母猪的踢腿、站立、躺、仔猪吸奶和仔猪远离母猪 5 种行为识别的 mAP 达到 95.89%。以上研究仅考虑了空间域的行为识别方法对研究对象的整体实现像素级分割,这对于高分辨率图像和大规模数据集,需要消耗大量的计算资源和时间,且目标粘连和遮挡等情况也会使模型检测与分割的难度显著增加^[25]。由于生猪活泼好动,其行为变化多样且持续时

间长,因此应充分结合空间域和时间域的信息进行生猪行为的识别与分析。

目前,现有生猪行为识别与分析方法存在目标特征提取过程复杂、易产生冗余特征信息以及缺少时序特征分析的问题。为此,本文考虑了生猪行为发生的连续性与动态性,提出了一种结合时空特征提取和时序建模技术的生猪行为识别方法,通过构建生猪特征点检测模型提取生猪活动视频中猪只不同行为下的特征点时序信息,再利用构建的生猪行为识别模型对时序信息进行建模与分析,实现生猪行为的准确识别,以为生猪行为识别提供一种新思路。

1 数据集构建

1.1 数据采集

生猪数据分别采集于浙江清渚农牧有限公司和浙江杭州高虹生猪养殖场,生猪品种均为长白猪,每栏约 7~10 头。猪舍整体空间呈长方形,内设水槽、食槽和通风装置。为便于全方位采集生猪数据,在猪舍顶部和侧边等多角度安装了海康摄像机,主要采集日间生猪活动频繁时段(07:00—17:00)的数据,共 52 段视频和 1 026 张原始图像。

1.2 生猪特征点检测数据集构建

生猪的鼻子和额头包含丰富的纹理和形态特征,有助于提升模型对生猪整体的识别和定位精度;生猪站立和行走主要依靠四肢及蹄尖支撑,通过检测这些部位可以有效捕捉生猪的运动特征;在坐姿状态下,生猪的重心后移,后肢、尾巴和臀部的相对位置和高度会发生变化,提供了重要的姿态信息;躺卧时,生猪身体的大部分区域接触地面,肩部和背部的相对位置变化能够较好地反映其躺卧姿态。为此,本文选取了生猪的鼻子、额头、肩部、身体(一般为背部)、臀部、尾巴、左前肢、左前蹄尖、右前肢、右前蹄尖、左后肢、左后蹄尖、右后肢和右后蹄尖共 14 个特征点。使用开源数据标注工具 X-AnyLabeling 标注生猪目标框和特征点,其中目标框信息主要包括目标框中心点的坐标以及目标框的宽和高;特征点信息包括该点的坐标及点的可见性,各点标注如图 1 所示。




图 1 生猪特征点标注

Fig.1 Pig feature points labeling

特征点数据标注规则为:1)针对生猪身体部位离开摄像画面而导致的特征点缺失情况,不进行缺失特征点的标注并将该点的可见性设置为 0,如图 2a 中的矩形框

处所示。2) 针对生猪特征点正常出现的情况, 进行特征点标注并将可见性设置为 1。3) 针对生猪身体位于画面中, 但由于摄像机视野的局限性或生猪的社会性交互行为导致的身体某些部位在画面中被遮挡的情况, 标注被遮挡的特征点并备注为 2, 如图 2b 中的矩形框处所示。




图 2 特征点标注特殊情况

Fig.2 Feature points labeling in special cases

为提高生猪特征点检测模型的泛化能力和检测精度, 按照 6:2:2 比例将数据划分为训练集、验证集和测试集, 并综合使用高斯噪声、椒盐噪声、图像锐化、像素镂空、亮度调节和图像平移等多种方式进行数据增强。经过离线增强后共保存 3 028 张图像, 用于构建生猪特征点检测数据集。

1.3 生猪行为数据集构建

为获取连续时间序列的生猪行为数据, 首先使用 YOLOv8 模型的追踪分支针对视频中的生猪进行追踪, 并将目标生猪周围的像素与画面中其他区域的像素差异化^[26], 从而生成生猪的行为视频。其次, 利用生猪特征

点检测模型逐帧检测生猪特征点, 获取生猪在 20~120 s 内 14 个特征点的坐标信息, 经过去重和清洗, 得到在时间序列上连续的行为数据, 并按照 6:2:2 的比例将数据划分为训练集、验证集和测试集, 用于模型的训练和评估。最终保存的生猪站、坐和躺 3 种行为的连续时间序列数据共 109 740 条, 表 1 统计了每种行为在 3 个时间序列内的数据条数。

表 1 不同时间序列的 3 种行为数据量
Table 1 Volumes of three types of behavioral data in different time series

时间序列 Time series/s	站 Standing	坐 Sitting	躺 Lying
20~60	11 830	10 263	11 240
61~90	12 453	11 350	10 897
91~120	15 153	11 650	14 904

为了直观展示生猪行为数据在时间序列上的特征分布, 以 3 s 为间隔, 分别绘制了生猪不同行为状态下身体 14 个特征点的坐标变化折线图, 如图 3 所示。

由图 3 可知, 生猪在站和坐 2 种姿态下, 身体特征点坐标折线呈规律性变化, 且存在一定的偏移现象, 表明生猪处于非静止状态, 而躺姿时的特征点坐标折线分布均匀, 表明生猪处于静态。总体来看, 同一行为状态下生猪特征点的坐标虽存在轻微的动态变化, 但在固定时间段内的空间分布整体较为稳定, 能够在时间序列上体现特征的连续性。因此, 捕捉生猪特征点的时序特征有助于生猪行为识别模型更精细地区分生猪的不同行为状态。




图 3 生猪不同行为状态下的特征点坐标在时间序列上的变化

Fig.3 Changes in the coordinates of feature points of pigs in different behavioral states over time series

2 生猪行为识别方法

分别构建生猪特征点检测模型 YOLO-ASF-P2 和生猪行为识别模型 CNN-BiGRU, 首先使用 YOLO-ASF-P2 对从猪舍监控视频中截取的生猪不同行为活动视频逐帧检测, 获取生猪特征点在时间序列上的位置特征, 再基于 CNN-BiGRU 模型对特征点的时序特征进行分析后识别生猪行为, 总体流程如图 4 所示。

2.1 生猪特征点检测模型

YOLOv8 是 Ultralytics 团队推出的性能强大的目标检测模型, 延用了 YOLO 系列模型的网络结构设计思想^[27-28]。YOLOv8-Pose 是 YOLOv8 模型的一个旨在处理姿态估计任务的分支, 主要用于识别图像中研究对象的

关键特征点, 输出每个点的坐标和置信度得分, 其最初在 COCO (common objects in context) 数据集^[29]上进行训练, 用以检测和识别人体关节的 17 个关键点。

生猪在运动过程中, 关节易呈现出模糊和畸变等现象, 存在目标特征点尺度变小的问题, 而 YOLOv8-Pose 的特征提取头部未包含 P2 层的信息, 使得其对小尺度目标特征的敏感度以及对复杂目标场景的适应能力下降。同时, YOLOv8-Pose 的特征融合部分主要依靠上采样操作恢复目标特征并进行特征拼接来实现不同分辨率特征的融合, 无法平衡多尺度特征的细节与全局信息, 从而对目标的检测效果有限^[30]。因此, 直接应用 YOLOv8-Pose 模型难以精准检测生猪特征点。此外, 由于生猪的行为复杂多样, 其特征点的细微变化可能受到遮挡、粘

连以及环境光照等外界干扰的影响,因此构建的特征点检测模型需具有较高的精度、较强的鲁棒性以及能满足猪场硬件资源有限的需求。为此,本文以 YOLOv8s-Pose 为基线模型进行改进。结合 YOLOv8s-Pose 模型 Backbone 部分的 P2 层提供的小目标细节特征信息与 ASF 架构设计思想,改进了其特征融合部分,分别添加了尺度特征融合模块(scale sequence feature fusion module, SSFF)、三重特征编码模块(triple feature encoding module, TFE)和通道和位置注意力机制(channel and position attention mechanism, CPAM)。SSFF 模块结合来自多尺度特征图的全局或高级语义信息,能最大限度地保留语义和空间信息,提高检测的鲁棒性和精度;TFE 模块用于捕捉小目标的局部精细细节,将局部信息和全局特征信息相结合可以获取更准确的目标特征;CPAM 用于捕获并细化与小目标相关的空间定位信息,提高模型的定位精度。将经上述改进后得到的生猪特征点检测模型命名为 YOLO-ASF-P2,其结构如图 5 所示。YOLO-ASF-P2 利用 4 个预测头对图像特征进行预测,生成目标的类别、边界框的坐标、生猪 14 个特征点的位置信息以及置信度。





图 4 生猪行为识别流程

Fig.4 Flowchart of pig behavior recognition



注:图中虚线部分为改进之处,P1~P5为不同层级的特征图,Stack为堆叠不同尺度特征的模块,3D Conv为使用 $1 \times 1 \times 1$ 的卷积核的三维卷积层,BN为批量标准化,SiLU为激活函数,Concat为特征连接模块,Bbox Loss和Cls Loss分别为边界框损失和分类损失,Split为特征图分割模块,Bottleneck为深度卷积模块, n 为Bottleneck的数量,Conv2d为单一的卷积模块。

Note: The dotted parts in the figure are improvements, P1-P5 are feature maps of different levels, Stack is a module for stacking features of different scales, 3D Conv is a three-dimensional convolution layer using a $1 \times 1 \times 1$ convolution kernel, BN is batch normalization, SiLU is the activation function, Concat is a feature connection module, Bbox Loss and Cls Loss are bounding box loss and classification loss respectively, Split is a feature map segmentation module, Bottleneck is a deep convolution module, n is the number of Bottleneck and Conv2d is a single convolution module.

图 5 YOLO-ASF-P2 模型结构

Fig.5 Structure of YOLO-ASF-P2 model

2.1.1 尺度特征融合模块

针对 YOLOv8s-Pose 模型特征提取部分 P2、P3、P4 和 P5 检测层输出的多尺度目标特征,尺度特征融合模块应用高斯核与最近邻插值方法,将不同下采样倍数的多尺度特征图对齐到与高分辨率特征图相同的分辨率,从而充分提取维度相同的深层特征图与浅层特征图的信息^[31]。

尺度特征融合模块首先使用标准差逐渐增加的高斯核对不同尺度的特征图进行卷积,计算式为

$$G_{\delta}(x, y) = \frac{1}{2\pi\delta^2} e^{-\frac{(x^2+y^2)}{2\delta^2}} \quad (1)$$

$$F_{\delta}(i, j) = \sum_u \sum_v f(i-u, i-v) \times G_{\delta}(u, v) \quad (2)$$

式中 x 和 y 分别为图像像素的横、纵坐标, δ 是标准差, G_{δ} 为高斯滤波函数, i 和 j 分别表示输出特征图 F_{δ} 中像素的横、纵坐标, u 和 v 分别表示高斯滤波函数 G_{δ} 的核窗口内像素的横、纵坐标, F_{δ} 是使用 G_{δ} 对特征图进行平滑处理后的结果。随着标准差 δ 的增大,高斯滤波函

数的平滑效果更强，能更好地平滑处理特征图中的细节。

在特征图卷积的基础上，尺度特征融合模块采用 1×1 卷积模块调整特征图通道数，将 P4 和 P5 级别特征图的通道数调整为 P3 级别特征图的通道数，将 P3 和 P4 特征级别的通道数调整为 P2 级别特征图的通道数；采用最近邻插值法将 P4 和 P5 级别特征图的大小调整为 P3 级别特征图的大小，将 P3 和 P4 级别特征图的大小调整为 P2 级别特征图的大小，以确保多尺度特征图在融合时保持一致。然后使用 `unsqueeze` 方法增加深度维数至特征图中，将特征图的维数由高度、宽度和通道数扩展为深度、高度、宽度和通道数。再使用 3D 卷积在深度维度上建立来自不同尺度特征的空间与语义信息，用于提升特征融合的效果，并降低计算复杂度。最后采用批归一化以及 SiLU 激活函数对堆叠后的特征图进行处理，从中提取多尺度特征，充分整合不同尺度特征的全局语义信息与局部细节信息，为后续的特征点检测提供更加精准的多尺度特征表达，以提高模型对生猪特征点的检测效果。

2.1.2 三重特征编码模块

三重特征编码模块用以均衡不同尺度特征图的细节信息，通过调整特征图的通道数和空间分辨率，避免模型在特征融合过程中丢失目标的关键特征，从而提升模型的检测性能^[32]。三重特征编码模块通过卷积模块将大尺寸特征图的通道数扩大两倍，将小尺寸特征图的通道数降低一半，使不同尺寸特征图的通道数调整为一致，确保后续特征融合阶段通道数的统一性，避免因通道维度不一致导致的运算冲突。针对大尺寸特征图，三重特征编码模块采用最大池化与平均池化的混合结构进行下采样，以平衡大尺寸特征图中保留的极值信息与整体均值信息，增强特征的平移不变性，提高模型的鲁棒性。而对于小尺寸特征图，三重特征编码模块使用最近邻插值方法进行上采样，利用相邻像素的信息填充特征图，保留小目标的特征信息。最后将维度相同的大、中、小 3 个特征图分别进行卷积操作，并且在通道维度进行拼接后输出。三重特征编码模块的结构如图 6 所示。

2.1.3 通道和位置注意力机制


为深度挖掘多通道特征信息并对其进行动态建模与高效利用以提升模型的特征表达能力，使用通道和位置注意力机制模块集成来自 SSFF 模块和 TFE 模块输出的详细特征信息。通道和位置注意力机制模块由通道注意力网络和位置注意力网络组成，其结构如图 7 所示。

通道注意力网络基于通道数 C 与卷积核大小 k 之间的非线性映射关系，动态调整注意力机制的覆盖范围，从而更高效地挖掘通道间的特征依赖性，见式 (3) ~ (4)。与传统池化方法不同，通道注意力网络首先对特征图的每个通道进行全局平均池化操作，保留每个通道的全局表示向量，以确保特征之间的依赖性能在后续步骤中被完整捕捉^[33]。再通过基于一维非线性卷积的局部交互机制，捕捉每个通道及其邻近通道的交互信息，其中卷积核大小 k 决定了参与交互的邻近通道数。

$$C = \alpha(k) = 2^{(\gamma k - \gamma')} \quad (3)$$

$$k = \alpha^{-1}(C) = \left\lfloor \frac{\log_2 C + \gamma'}{\gamma} \right\rfloor_{\text{odd}} \quad (4)$$

式中 α 用于建立非线性映射关系，缩放参数 γ 和 γ' 分别通过调节卷积核的大小和通道数的变化控制卷积核 k 与通道数 C 的比值。经验证， γ 和 γ' 的初始值设置为 2 和 1 时，网络的泛化能力和特征表达效果最佳， $\lfloor \cdot \rfloor_{\text{odd}}$ 表示取最近邻的奇数值。



注：Large、Medium 和 Small 表示大、中和小 3 个尺度的特征图， C 表示通道数， S 表示特征图的大小，ConvBNSiLU 为卷积平滑模块，MaxPooling 为最大池化模块，AvgPooling 为平均池化模块，Nearest 表示最近邻插值模块，Concat 表示特征融合操作。

Note: Large, Medium, and Small represent feature maps of large, medium, and small scales. C represents the number of channels, S represents the size of the feature map, ConvBNSiLU represents the convolution smoothing module, MaxPooling represents the maximum pooling module, AvgPooling represents the average pooling module, Nearest represents the nearest neighbor interpolation module, and Concat represents the feature fusion operation.

图 6 三重特征编码模块结构

Fig.6 Structure of triple feature encoding (TFE) module

位置注意力网络将通道注意力网络的输出与 SSFF 模块的输出相结合作为输入，提取生猪特征点的重要空间信息。首先，位置注意力网络分别在特征图的宽度和高度方向上进行平均池化，以保留更多特征图的空间结构信息，池化计算见式 (5) ~ (6)；再将水平池化和垂直池化的结果在通道维度上进行拼接，并对拼接后的结果进行卷积操作，得到融合后的位置注意力特征图，见式 (7)；最后，将位置注意力坐标在通道维度上分解为与宽度和高度相关的 2 个位置依赖特征图并对位置依赖特征图应用 Sigmoid 激活函数，得到归一化后的注意力权重 S_{ws} 和 S_{hs} ，见式 (8) ~ (9)。

$$p_w(i') = \frac{1}{H_i} \sum_{j'=0}^{H_i} E(i', j') \quad (5)$$


$$p_h(j') = \frac{1}{W_i} \sum_{i'=0}^{W_i} E(i', j') \quad (6)$$

$$P(a_w, a_h) = \text{Conv}[\text{Concat}(p_w, p_h)] \quad (7)$$

$$S_{ws} = \sigma(\text{Split}(a_w)) \quad (8)$$

$$S_{hs} = \sigma(\text{Split}(a_h)) \quad (9)$$

式中 W_i 和 H_i 分别是输入特征图的宽度和高度, $E(i', j')$ 是输入特征图在位置 (i', j') 处的值。 $P(a_w, a_h)$ 表示位置注意力特征图, a_w 、 a_h 分别为宽度和高度的位置依赖特征图, Conv 表示卷积操作, Concat 表示串联拼接操作。 σ 表示 Sigmoid 激活函数。



注: Conv1D 表示 1×1 卷积层, Sigmoid 为激活函数, $\otimes$ 表示逐特征融合, p_w 和 p_h 分别表示水平和垂直池化后的结果, S_{ws} 和 S_{hs} 分别表示特征图宽度和高度方向的位置注意力权重。
Note: Conv1D represents the 1×1 convolutional layer, Sigmoid is the activation function, $\otimes$ represents element-by-element multiplication. p_w and p_h represent the results after horizontal and vertical pooling, respectively, S_{ws} and S_{hs} represent the position attention weights in the width and height directions of the feature map, respectively.

图 7 通道和位置注意力机制结构

Fig.7 Structure of channel and position attention mechanism (CPAM) module

2.1.4 目标框损失函数优化

改进前的 YOLOv8s-Pose 模型使用的 CIoU 损失函数虽然考虑了目标框回归的重叠面积、中心点距离和长宽比, 但其针对目标框的形状分析不准确^[34]。为使检测更为精准, 将原有损失函数替换为 EIou 损失函数^[35]。EIou 在考虑重叠面积和中心点距离对损失函数产生影响的同时, 还考虑了目标框的宽和高对损失函数的影响, 不仅关注目标框之间的重叠区域, 还关注其他非重合区域, 从而提高目标的检测效果。EIou 损失计算式如下:


$$L_{EIou} = 1 - \text{IoU} + \frac{\rho^2(b, b_{gt})}{W_c^2 + H_c^2} + \frac{\rho^2(W, W_{gt})}{W_c^2} + \frac{\rho^2(H, H_{gt})}{H_c^2} \quad (10)$$

式中 IoU 为真实目标框与预测目标框之间的交并比, b 和 b_{gt} 分别表示预测目标框和真实目标框的中心点坐标,

$\rho^2(b, b_{gt})$ 表示两者之间的欧式距离, W 和 H 分别为预测目标框的宽和高, W_{gt} 和 H_{gt} 分别为真实边界框的宽和高, W_c 和 H_c 分别为真实目标框和预测目标框最小外包框的宽和高。

2.2 生猪行为识别模型

循环神经网络 (recurrent neural network, RNN) 是一种专门用于处理序列数据的神经网络, 在信息反向传播过程中会出现梯度消失或梯度爆炸问题, 因此难以有效捕捉序列中的长期依赖关系, 通常只具有短期记忆能力^[36]。门控循环单元 (gated recurrent unit, GRU) 是 RNN 的变种, 通过引入门控机制控制信息的流动, 只需更新门和重置门并使用隐藏状态传递信息, 结构简洁, 有效地解决了 RNN 短期记忆的问题, 使得模型能够捕获长期依赖关系^[37]。门控循环单元的结构如图 8 所示。



注: x_t 、 $\tilde{h}_t$ 和 h_t 分别为 t 时刻模型的输入、历史候选状态和隐藏状态, z_t 表示更新门的输出, 用于控制历史状态的权重, r_t 表示重置门的输出, 用于控制模型对历史候选状态的影响, $\oplus$ 为逐元素加法。
Note: x_t , $\tilde{h}_t$ and h_t are the input, historical candidate state and hidden state of the model at time t , respectively. z_t represents the output of the update gate, which is used to control the weight of the historical state. r_t represents the output of the reset gate, which is used to control the influence of the model on the historical candidate state, $\oplus$ is element-wise addition.

图 8 门控循环单元结构

Fig.8 Structure of gated recurrent unit (GRU)

GRU 更新门的计算见式 (11), 重置门的计算见式 (12), 历史候选状态的计算见式 (13), 隐藏状态的计算见式 (14)。

$$z_t = \sigma[E_z \times (h_{t-1}, x_t)] \quad (11)$$

$$r_t = \sigma[E_r \times (h_{t-1}, x_t)] \quad (12)$$


$$\tilde{h}_t = \tanh(E_h \times [(h_{t-1} \odot r_t), x_t]) \quad (13)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (14)$$

式中 E_z 、 E_r 和 E_h 为神经网络反向传播得到的参数矩阵, $\odot$ 表示逐元素相乘。

为充分利用 YOLO-ASF-P2 提取的生猪时序特征识别生猪的行为, 本文基于门控循环单元构建了生猪行为识别模型 CNN-BiGRU, 其结构如图 9 所示。

双向门控循环单元 (bidirectional gated recurrent unit, BiGRU) 是 CNN-BiGRU 的核心, 该单元分别按照时间序列正向和反向处理数据。通过这种双向结构, BiGRU 单元能够同时捕捉序列数据的前向和后向信息, 从而提高模型对上下文的理解能力^[38]。模型首先使用卷积层提取生猪时序特征点数据的局部特征, 再应用 BiGRU 单元进行时间序列建模, 并对 BiGRU 单元的输出应用注意力机制生成加权输出, 最后通过全连接层输出生猪行为类别。



注：\$x\$ 和 \$y\$ 为图像像素的横、纵坐标，Dropout 为正则化操作，AttentionBlock 为实现加权输出的注意力机制模块，FCLayer 为全连接层，LeakyReLU 和 Softmax 为激活函数。

Note: \$x\$ and \$y\$ are the horizontal and vertical coordinates in the image, Dropout is a regularization operation, AttentionBlock is an attention mechanism module for weighted output, FCLayer is a fully connected layer, and LeakyReLU and Softmax are activation functions.

图 9 CNN-BiGRU 模型结构
Fig.9 Structure of CNN-BiGRU model

图 9 中，BiGRU 单元的输出 \$h_t\$ 是前向隐藏层状态和后向隐藏层状态的加权和，计算见式 (15) ~ (17)。

$$\vec{h} = \text{GRU}(x_t, \vec{h}_{t-1}) \quad (15)$$

$$\overleftarrow{h} = \text{GRU}(x_t, \overleftarrow{h}_{t-1}) \quad (16)$$

$$h_t = f(\vec{Q} \cdot \vec{h}_t + \overleftarrow{Q} \cdot \overleftarrow{h}_t + b_t) \quad (17)$$

式中 \$\vec{h}\$ 和 \$\overleftarrow{h}\$ 分别为 \$t\$ 时刻前向隐藏层与后向隐藏层的状态，\$\vec{Q}\$ 和 \$\overleftarrow{Q}\$ 分别为前向隐藏层和后向隐藏层状态的权重，\$b_t\$ 为偏置项。

在信息的前向传播过程中，CNN-BiGRU 中的 AttentionBlock 注意力机制模块能针对每个时间步的重要性进行加权，从而更好地捕捉序列中的关键信息^[39]。其首先对输入进行线性变换，然后应用 Softmax 激活函数计算注意力权重，最后将输入和权重逐元素相乘，返回加权后的结果，具体实现如下：

$$a = W_a \cdot g + b' \quad (18)$$

$$a_{\text{probs}} = \text{Softmax}(a) \quad (19)$$

$$\text{Output} = x' \odot a_{\text{probs}} \quad (20)$$

式中 \$W_a\$ 表示权重矩阵，\$g\$ 表示 BiGRU 单元的输出，\$b'\$ 表示线性变换中的偏置项，\$a\$ 表示对输入应用线性变换后的结果，\$a_{\text{probs}}\$ 表示所得注意力权重，\$x'\$ 表示模型的输入，Output 表示加权后的结果。

3 试验结果与分析

3.1 试验环境

试验在 Ubuntu 24.04 LTS 操作系统、Intel Core i7-13700KF CPU 和 Nvidia GeForce RTX4090 显卡的服务器上进行，同时配置了 CUDA 12.0，采用 Pytorch 2.1.0 深度学习框架基于 Python 3.9 编写 Python 程序。

3.2 评价指标

采用精度 (\$P\$) 召回率 (\$R\$)、平均精度 (average precision, \$A_p\$)、模型参数量、浮点运算次数 (Floating point of operations, FLOPs)、目标关键点相似度 (object keypoint similarity, \$O_{\text{KS}}\$)、F1 分数 (F1 score)、宏平均

(\$A_m\$)、加权平均 (\$A_w\$) 以及帧率 (frames per second, FPS) 共 9 个指标对所提模型进行综合评价。各项指标的计算式如下：

$$P = \frac{T_P}{T_P + F_P} \quad (21)$$

$$R = \frac{T_P}{T_P + F_N} \quad (22)$$

$$A_p = \int_0^1 P(R) dR \quad (23)$$

$$O_{\text{KS}} = \frac{\sum_q \exp(-\frac{d_q^2}{2D^2k_q^2})\varepsilon(v_q > 0)}{\sum_q \varepsilon(v_q > 0)} \quad (24)$$

$$F1 = \frac{2PR}{P+R} \quad (25)$$

$$A_m = \frac{1}{N} \sum_{q=1}^N M_q \quad (26)$$

$$A_w = \frac{1}{T} \sum_{q=1}^N n_q \cdot M_q \quad (27)$$

$$\text{FPS} = \frac{F_{\text{total}}}{T_{\text{total}}} \quad (28)$$

式中 \$T_P\$、\$F_P\$ 和 \$F_N\$ 分别表示正确预测的生猪特征点的数量、将非生猪特征点预测为生猪特征点的数量和错误地将生猪特征点预测为非生猪特征点的数量，\$A_p\$ 为平均精度；\$d_q\$ 是每个真实的特征点和预测特征点之间的欧氏距离；\$v_q\$ 是特征点可见性标记，\$\varepsilon\$ 表示特征点的归一化因子，这个因子是通过对所有特征点计算标准差而得到的，\$D\$ 是目标的尺度，\$k_q\$ 是第 \$q\$ 个关键点的常量；\$P\$ 表示精度，\$R\$ 表示召回率，\$N\$ 表示类别数，\$q\$ 表示对类别的索引，\$M_q\$ 表示不同的指标 (包括 \$P\$、\$R\$ 和 \$F1\$)，\$n_q\$ 表示样本数量，\$T\$ 定义为所有类别样本的数量之和，FPS 单位为帧/s，\$F_{\text{total}}\$ 表示已处理的总帧数，\$T_{\text{total}}\$ 表示处理时间之和。

3.3 生猪特征点检测试验结果分析

3.3.1 不同损失函数试验效果对比

图 10 对比了原始 YOLOv8s-Pose 模型、使用了 EIoU 损失函数的 YOLOv8s-Pose 模型及本文提出的 YOLO-

ASF-P2 模型在训练过程中的损失变化。由图 10 可知, 随着训练迭代次数的增加, 3 种模型的损失值逐渐减小, 在第 275 轮左右均趋于收敛; 同时, 在第 30 轮次开始, 使用了 EIoU 损失函数的 2 种模型的损失较原始模型更低, 直至趋于收敛。




图 10 目标框损失值对比曲线

Fig.10 Comparison of bounding box loss curves

3.3.2 对比试验

为验证 YOLO-ASF-P2 模型的性能, 选取了同系列的 YOLOv5s-Pose、YOLOv7s-Pose 和 YOLOv8s-Pose 模型, 以及不同系列的 MMPose 和 RTMPose 模型设计了对比试验。模型迭代周期为 300 轮, 批量大小为 32, 初始学习率为 0.01, 在模型训练中使用 SGD 优化器进行迭代优化。由表 2 所示的对比结果可知, YOLO-ASF-P2 模型的参数量仅为 18.4 M, 能较好地满足快速检测任务的需求, 此外, 相比 MMPose, YOLO-ASF-P2 的平均精度 ($AP_{50\sim95}$) 和精度分别提升了 17.4 % 和 2.9%; 相比 RTMPose, YOLO-ASF-P2 的精度、召回率和平均精度 ($AP_{50\sim95}$) 分别提升了 17.7%、12.9% 和 28.0%, 且参数量降低近 200 M; 相比 YOLOv5s-Pose, YOLO-ASF-P2 的精度相同且召回率和平均精度 ($AP_{50\sim95}$) 分别提升了 1.4% 和 1.2%; 相比 YOLOv7s-Pose, YOLO-ASF-P2 的精度略有下降, 但召回率和平均精度 ($AP_{50\sim95}$) 分别提升了 4.0% 和 1.8%, 且参数量更小, 模型更加轻量化; 相比基线模型 YOLOv8s-Pose, YOLO-ASF-P2 对于生猪特征点的检测性能在精度、召回率和平均精度 ($AP_{50\sim95}$) 上分别提升了 1.1%、2.3% 和 1.5%, 同时参数量明显下降。综上, YOLO-ASF-P2 模型在保持较低参数量的同时, 实现了较高的检测精度和召回率, 综合性能较好, 能够满足生猪特征点准确检测的需求。

表 2 不同检测模型对比试验结果

Table 2 Comparison results of different detection models

模型 Model	精度 Precision P/%	召回率 Recall R/%	平均精度 Average precision $AP_{50\sim95}/\%$	参数量 Parameter/ M	浮点运算 次数 FLOPs/G
MMPose	89.9	90.9	58.1	9.4	7.7
RTMPose	78.6	79.7	53.3	212.0	4.2
YOLOv5s-Pose	92.5	88.8	67.4	13.9	29.8
YOLOv7s-Pose	93.1	86.5	67.0	39.1	26.3
YOLOv8s-Pose	91.5	88.0	67.2	22.3	29.8
YOLO-ASF-P2	92.5	90.0	68.2	18.4	39.6

注: $AP_{50\sim95}$ 为 O_{KS} 阈值设置在 0.5 到 0.95 之间, 步长设置为 0.05 下的 10 个阈值的平均精度。

Note: $AP_{50\sim95}$ is the average accuracy of 10 thresholds under O_{KS} thresholds set between 0.5 and 0.95, and the step size is set to 0.05.

3.3.3 消融试验

为验证 YOLO-ASF-P2 的目标检测性能, 将基线模型 YOLOv8s-Pose 分别与不同模块搭配设计消融试验, 结果见表 3。从表 3 可以看出, 将原始 YOLOv8s-Pose 模型的损失函数替换为 EIoU 后, 模型参数量和浮点运算次数均不变, 精度和召回率略微下降, 平均精度 ($AP_{50\sim95}$) 略微上升; 结合 ASF 架构改进基线模型的特征融合部分后, 模型融合了目标更多特征信息, 召回率和平均精度略微下降, 精度略微上升, 参数量略微增加, 由于模型结构更复杂, 导致浮点运算次数上升了 6.4%; 在基线模型中加入 P2 层大分辨率特征图提供的更多目标细节信息后, 浮点运算次数上升了 35.9%, 模型参数量降低了 3.6%, 召回率略微下降, 精度和平均精度 ($AP_{50\sim95}$) 分别提高了 0.3% 和 1.6%; 在基线模型中加入改进后的特征融合部分用于处理 P2 层提供的丰富特征信息后, 浮点运算次数上升了 32.9%, 召回率相差无几, 精度略微下降, 平均精度 ($AP_{50\sim95}$) 略微上升, 但参数量降低了 17.5%, 模型体积缩小; 相比基线模型, 各项改进融合后的 YOLO-ASF-P2 模型的精度、召回率和平均精度 ($AP_{50\sim95}$) 分别上升了 1.1%、2.3% 和 1.5%, 浮点运算次数上升了 32.9%, 参数量仅有 18.4 M, 降低了 17.5%。综上, YOLO-ASF-P2 的检测性能最佳, 且更加轻量化。

表 3 消融试验结果

Table 3 Ablation test results

ASF	P2	EIoU	精度 Precision P/%	召回率 Recall R/%	平均精度 $AP_{50\sim95}/\%$	参数量 Parameter/ M	浮点运算次数 FLOPs/ G
×	×	×	91.5	88.0	67.2	22.3	29.8
√	×	×	91.8	87.4	66.8	22.6	31.7
×	√	×	91.8	87.7	68.3	21.5	40.5
×	×	√	91.2	87.8	67.4	22.3	29.8
√	√	×	90.0	87.9	68.0	18.4	39.6
√	×	√	91.9	88.2	67.5	22.6	31.7
×	√	√	92.4	85.7	68.4	21.5	40.5
√	√	√	92.5	90.0	68.2	18.4	39.6

注: √代表添加该模块, ×代表不添加该模块, 表格第一行代表基线模型 YOLOv8s-Pose。

Note: √ represents adding the module, × represents not adding the module, and the first row of the table represents the baseline model YOLOv8s-Pose.

为直观展示 YOLO-ASF-P2 的性能, 使用 Grad-CAM^[40] 将其检测结果进行了可视化, 并与改进前模型 YOLOv8s-Pose 进行了对比, 如图 11 所示。图中, 矩形框展示了生猪位于图片边缘区域时, 仅部分身体可见且可见部位的尺度明显变小的情况。由图 11 可知, 相比 YOLOv8s-Pose, YOLO-ASF-P2 模型的热力图在生猪的背部、臀部、肩部和腿部等区域均更高亮。同时, 该模型还能更准确地定位和捕捉躯体不完整且尺度变小的生猪部分特征点。这表明 YOLO-ASF-P2 对生猪特征点的关注程度更高, 模型的鲁棒性更强。这得益于 YOLO-ASF-P2 模型引入了 P2 层的丰富特征, 并通过改进后的特征融合部分更高效地融合小尺度特征信息, 从而确保时序数据的高质量采集, 使后续基于时间序列的行为建模更加可靠。




图 11 不同模型检测性能的热力图
Fig.11 Heatmaps of detection performance of different models

3.4 生猪行为识别结果分析

使用 RMSprop 优化器、StepLR 学习率调度器和交叉熵损失函数对生猪行为识别模型 CNN-BiGRU 进行训练，训练轮次为 80。模型在不同时间序列长度的生猪行为测试集中的识别结果如表 4 所示。由表 4 可知，CNN-BiGRU 针对生猪的坐、站和躺 3 种行为的识别精度、召回率和 F1 分数的宏平均及加权平均的结果均不低于 95%，总体表现出较高的识别精度和较好的鲁棒性。其中，生猪躺行为的识别效果较差，是由于生猪躺行为相对易出现特征点遮挡所导致。

表 4 生猪行为识别结果

Table 4 Pig behavior recognition results

类别 Category	精度 Precision P/%	召回率 Recall R/%	F1 分数 F1 score/%
坐 Sitting	100.0	100.0	100.0
躺 Lying	89.2	95.4	91.4
站 Standing	98.1	95.3	97.2
宏平均 A_m	95.8	96.9	96.2
加权平均 A_w	95.8	95.7	95.9

为进一步验证本文提出的生猪行为识别模型的性能，基于卷积神经网络和注意力机制模块设计了对比试验。各模型在测试集中针对生猪的坐、站和躺 3 种行为的识别结果如表 5 所示。

表 5 不同识别模型对比试验结果

Table 5 Comparison results of different recognition models

模型 Model	平均精度 Average precision A_p /%	平均召回率 Average recall A_r /%	平均 F1 分数 Average F1 score/%	参数量 Parameter/ M	帧率 Frames per second FPS/ (帧·s ⁻¹)	浮点运算 次数 FLOPs/G
BiGRU	84.4	82.8	83.1	0.129	166	13.3
BiGRU-A	86.5	90.0	88.3	0.097	221	18.3
CNN-BiGRU	87.6	93.2	88.7	0.095	132	18.9
CNN-BiGRU-A	95.8	96.9	96.2	0.151	156	27.1

注：A 代表添加 AttentionBlock 注意力机制模块。
Note: A represents adding the AttentionBlock attention mechanism module.

由表 5 可知，相比 BiGRU，添加注意力机制模块后的模型通过动态加权重要特征减少了高维特征的冗余信

息流动，其平均精度、平均召回率、平均 F1 分数、和浮点运算次数均有提升，同时参数量明显下降；加入 CNN 结构的模型通过卷积操作捕捉时序数据间的局部依赖关系，在降低输入特征维度的同时提高了特征表达能力，使得后续全连接层需要处理的维度降低，相比基线模型，其浮点运算次数升高，FPS 减小，且参数量更低，模型性能更好；两者融合后的 CNN-BiGRU 模型能够通过加权整合时间序列中各个时刻的生猪行为信息动态调整模型的关注点，虽 FPS 略微下降，参数量略微上升，但其平均精度、平均召回率和平均 F1 分数比基线模型分别提升了 13.5%、17.0% 和 15.8%，对生猪行为的识别效果最佳，表现出较强的综合性能。

4 结 论

本文提出了一种结合生猪时序特征提取和时序建模技术识别生猪不同行为的方法，分别构建了生猪特征点检测模型 YOLO-ASF-P2 和生猪行为识别模型 CNN-BiGRU。基于 YOLOv8s-Pose 模型改进的生猪特征点检测模型 YOLO-ASF-P2，有效应对因生猪日常活动时特征点发生明显尺度变化导致特征点检测难度大的问题，实现了生猪特征点的高精度识别，优化了生猪特征提取方式。在特征点检测的基础上，结合时间域信息提出的生猪行为识别模型 CNN-BiGRU，实现了生猪坐、站和躺 3 种行为较高精度的识别。具体结论如下：

1) 生猪特征点检测模型 YOLO-ASF-P2 通过融合多尺度特征信息、聚焦局部特征细节、细化小目标空间定位信息以及改进损失函数实现了生猪特征点的高精度检测。经验证，YOLO-ASF-P2 对于生猪特征点的检测性能的精度、召回率、平均精度 ($AP_{50\sim95}$) 和浮点运算次数分别为 92.5%、90.0%、68.2%、39.6 G，较改进前分别提升了 1.1%、2.3%、1.5% 和 32.9%，参数量降低了 17.5%，仅有 18.4 M。YOLO-ASF-P2 在多尺度特征融合能力和轻量化方面表现突出，适合在资源受限的环境中部署，为生猪特征点准确检测提供了技术支持。

2) 生猪行为识别模型 CNN-BiGRU 通过捕捉局部生猪行为特征结合注意力机制动态聚焦重要时间步的特征，显著提升了生猪行为识别的准确性。经验证，所提模型在自建测试集中针对生猪的坐、站和躺 3 种行为的平均识别精度为 95.8%，浮点运算次数为 27.1 G，模型参数量为 0.151 M，识别性能良好，能够有效分析基于时间序列的生猪特征点信息，从而识别生猪的行为。

本文提出的方法为生猪的行为识别提供了新思路，未来可进一步研究生猪在社会性交互状态下的特征提取方法和行为识别方法。

[参 考 文 献]

[1] BORGES OLIVEIRA D A, RIBEIRO PEREIRA L G, BRESOLIN T, et al. A review of deep learning algorithms for computer vision systems in livestock[J]. *Livestock Science*, 2021, 253: 104700.

- [2] 靳敏. 基于机器学习的猪只行为识别与分类方法研究[D]. 呼和浩特: 内蒙古农业大学, 2021.
JIN Min. Identification and Classification Methods of Pig Behavior Based on Machine Learning[D]. Hohhot: Inner Mongolia Agricultural University, 2021. (in Chinese with English abstract)
- [3] 吴世海, 鲍义东, 陈果, 等. 基于机器视觉技术的猪行为活动无接触识别系统[J]. 计算机系统应用, 2020, 29(4): 113-117.
WU Shihai, BAO Yidong, CHEN Guo, et al. Contactless identification system for pig behavior based on machine vision[J]. Computer Systems & Applications, 2020, 29(4): 113-117. (in Chinese with English abstract)
- [4] GARCIA R, AGUILAR J, TORO M, et al. A systematic literature review on the use of machine learning in precision livestock farming[J]. *Computers and Electronics in Agriculture*, 2020, 179: 105826.
- [5] 黄志杰, 徐爱俊, 周素茵, 等. 融合重参数化和注意力机制的猪脸关键点检测方法[J]. *农业工程学报*, 2023, 39(12): 141-149.
HUANG Zhijie, XU Aijun, ZHOU Suyin, et al. Key point detection method for pig face fusing reparameterization and attention mechanisms[J]. *Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE)*, 2023, 39(12): 141-149. (in Chinese with English abstract)
- [6] 沈明霞, 陈金鑫, 丁奇安, 等. 生猪自动化养殖装备与技术看研究进展与展望[J]. *农业机械学报*, 2022, 53(12): 1-19.
SHEN Mingxia, CHEN Jinxin, DING Qi'an, et al. Current situation and development trend of pig automated farming equipment application[J]. *Transactions of the Chinese Society for Agricultural Machinery*, 2022, 53(12): 1-19. (in Chinese with English abstract)
- [7] WANG Z, ZHOU S, YIN P, et al. GANPose: Pose estimation of grouped pigs using a generative adversarial network[J]. *Computers and Electronics in Agriculture*, 2023, 212: 108119.
- [8] 苑朝, 赵亚冬, 张耀, 等. 基于 YOLO 轻量化的多模态行人检测算法[J]. *图学学报*, 2024, 45(1): 35-19.
YUAN Chao, ZHAO Yadong, ZHANG Yao, et al. Base on YOLO lightweight multi-modal pedestrian detection algorithm[J]. *Journal of Graphics*, 2024, 45(1): 35-19. (in Chinese with English abstract)
- [9] 傅裕, 高树辉. 改进 YOLOv8s-Pose 多人姿态估计轻量化模型研究[J]. *计算机科学与探索*, 2025, 19(3): 682-692.
FU Yu, GAO Shuhui. Research on the lightweight model of multi-person pose estimation based on the improved YOLOv8s-Pose[J]. *Journal of Frontiers of Computer Science and Technology*, 2025, 19(3): 682-692. (in Chinese with English abstract)
- [10] 徐红梅, 杨浩, 李亚林, 等. 基于改进 YOLO-Pose 的复杂环境下拖拉机驾驶员关键点检测[J]. *农业工程学报*, 2023, 39(16): 139-149.
XU Hongmei, YANG Hao, LI Yalin, et al. Detecting the key points of tractor drivers under complex environments using improved YOLO-Pose[J]. *Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE)*, 2023, 39(16): 139-149. (in Chinese with English abstract)
- [11] FANG H, LI J, TANG H, et al. AlphaPose: Whole-Body regional multi-person pose estimation and tracking in real-time[EB/OL]. (2022-11-07)[2024-12-30]. <https://arxiv.org/abs/2211.03375>.
- [12] 王鲁, 刘晴, 曹月, 等. 基于改进 Cascade Mask R-CNN 与协同注意力机制的群猪姿态识别[J]. *农业工程学报*, 2023, 39(4): 144-153.
WANG Lu, LIU Qing, CAO Yue, et al. Posture recognition of group-housed pigs using improved Cascade Mask R-CNN and cooperative attention mechanism[J]. *Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE)*, 2023, 39(4): 144-153. (in Chinese with English abstract)
- [13] SHAO H, PU J, MU J. Pig-posture recognition based on computer vision: Dataset and exploration[J]. *Animals*, 2021, 11: 1295.
- [14] NASIRAHMADI A, STURM B, EDWARDS S, et al. Deep learning and machine vision approaches for posture detection of individual pigs[J]. *Sensors*, 2019, 19: 3738.
- [15] 李丹, 张凯锋, 李行健, 等. 基于 Mask R-CNN 的猪只爬跨行为识别[J]. *农业机械学报*, 2019, 50(S1): 261-266, 275.
LI Dan, ZHANG Kaifeng, LI Xingjian, et al. Mounting behavior recognition for pigs based on Mask R-CNN[J]. *Transactions of the Chinese Society for Agricultural Machinery*, 2019, 50(S1): 261-266, 275. (in Chinese with English abstract)
- [16] YANG Q, XIAO D, LIN S. Feeding behavior recognition for group-housed pigs with the Faster R-CNN[J]. *Computers and Electronics in Agriculture*, 2018, 155: 453-460.
- [17] 滕光辉, 冀横溢, 庄晏榕, 等. 深度学习在猪只饲养过程的应用研究进展[J]. *农业工程学报*, 2022, 38(14): 235-249.
TENG Guanghui, JI Hengyi, ZHUANG Yanrong, et al. Research progress of deep learning in the process of pig feeding[J]. *Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE)*, 2022, 38(14): 235-249. (in Chinese with English abstract)
- [18] 姚砺, 王梦珂, 万燕, 等. 基于骨架序列的校园斗殴行为检测研究[J]. *计算机应用与软件*, 2024, 41(12): 193-200, 274.
YAO Li, WANG Mengke, WAN Yan, et al. Campus fighting behavior detection based on skeleton sequences[J]. *Computer Applications and Software*, 2024, 41(12): 193-200, 274.
- [19] 李朝, 赵霞, 赵继康, 等. 基于人体特征点提取和多维时间序列分类的驾驶行为识别方法[J/OL]. *机械工程学报*, 1-14[2024-12-29]. <https://kns-cnki-net.webvpn.zafu.edu.cn/kcms/detail/11.2187.th.20240819.0948.004.html>.

- LI Zhao, ZHAO Xia, ZHAO Jikang, et al. Driving behavior recognition based on human feature point extraction and multidimensional time series classification[J/OL]. *Journal of Mechanical Engineering*, 1-14[2024-12-29]. <https://kns-cnki-net.webvpn.zafu.edu.cn/kcms/detail/11.2187.th.20240819.0948.004.html>. (in Chinese with English abstract)
- [20] 董力中, 孟祥宝, 潘明, 等. 基于姿态与时序特征的猪只行为识别方法[J]. *农业工程学报*, 2022, 38(5): 148-157.
- DONG Lizhong, MENG Xiangbao, PAN Ming, et al. Recognizing pig behavior on posture and temporal features using computer vision[J]. *Transactions of the Chinese Society of Agricultural Engineering(Transactions of the CSAE)*, 2022, 38(5): 148-157. (in Chinese with English abstract)
- [21] WANG M, OCZAK M, LARSEN M, et al. A PCA-based frame selection method for applying CNN and LSTM to classify postural behaviour in sows[J]. *Computers and Electronics in Agriculture*, 2021, 189: 106351.
- [22] YANG Q, XIAO D, CAI J. Pig mounting behaviour recognition based on video spatial-temporal features[J]. *Biosystems Engineering*, 2021, 206: 55-66.
- [23] LIU D, OCZAK M, MASCHAT K, et al. A computer vision-based method for spatial-temporal action recognition of tail-biting behaviour in group-housed pigs[J]. *Biosystems Engineering*, 2020, 195: 27-41.
- [24] ZHANG Y, YANG X, LIU Y, et al. A time-series neural network for pig feeding behavior recognition and dangerous detection from videos[J]. *Computers and Electronics in Agriculture*, 2024, 218: 108710.
- [25] CHEN C, ZHU W, NORTON T. Behaviour recognition of pigs and cattle: Journey from computer vision to deep learning[J]. *Computers and Electronics in Agriculture*, 2021, 187: 106255.
- [26] NASIRI A, YODER J, ZHAO Y, et al. Pose estimation-based lameness recognition in broiler using CNN-LSTM network[J]. *Computers and Electronics in Agriculture*, 2022, 197: 106931.
- [27] REDMON J, FARHADI A. YOLOv3: An incremental improvement[EB/OL]. (2018-04-08)[2024-07-09]. <https://arxiv.org/abs/1804.02767>.
- [28] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: Optimal speed and accuracy of object detection[EB/OL]. (2020-04-23)[2024-07-09]. <https://arxiv.org/abs/2004.10934>.
- [29] LIN T Y, MAIRE M, BELONGIE S, et al. Microsoft COCO: Common objects in context[EB/OL]. (2015-02-21)[2024-07-09]. <https://arxiv.org/abs/1405.0312>.
- [30] LI J, GREEN-MILLER A R, HU X, et al. Barriers to computer vision applications in pig production facilities[J]. *Computers and Electronics in Agriculture*, 2022, 200: 107227.
- [31] KANG M, TING C M, TING F F, et al. ASF-YOLO: A novel YOLO model with attentional scale sequence fusion for cell instance segmentation[J]. *Image and Vision Computing*, 2024, 147: 105057.
- [32] 王琳毅, 白静, 李文静, 等. YOLO 系列目标检测算法研究进展[J]. *计算机工程与应用*, 2023, 59(14): 15-29.
- WANG Linyi, BAI Jing, LI Wenjing, et al. Research progress of YOLO series target detection algorithms[J]. *Computer Engineering and Applications*. 2023, 59(14): 15-29. (in Chinese with English abstract)
- [33] 李和平, 陈中举, 许浩然, 等. 改进 YOLO 的钢材表面缺陷检测算法[J]. *现代电子技术*, 2024, 47(13): 7-14.
- LI Heping, CHEN Zhongju, XU Haoran, et al. Improved YOLO steel surface defect detection algorithm[J]. *Modern Electronics Technique*. 2024, 47(13): 7-14. (in Chinese with English abstract)
- [34] REZATOFIGHI H, TSOI N, GWAK J, et al. Generalized intersection over union: A metric and a loss for bounding box regression[EB/OL]. (2019-04-15)[2024-07-09]. <https://arxiv.org/abs/1902.09630>.
- [35] ZHANG Y F, REN W, ZHANG Z, et al. Focal and efficient IOU loss for accurate bounding box regression[EB/OL]. (2022-07-16)[2024-07-09]. <https://www.arxiv.org/abs/2101.08158>.
- [36] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. *Neural computation*, 1997, 9: 1735-1780.
- [37] CHUNG J, GULCEHRE C, CHO K, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[EB/OL]. (2014-12-11)[2024-07-09]. <https://arxiv.org/abs/1412.3555>.
- [38] 王超, 孙喁喁, 徐飞, 等. 结合 CNN 和 BiGRU 的双通道短文本意图识别算法[J]. *计算机系统应用*, 2024, 33(5): 136-143.
- WANG Chao, SUN Yongyong, XU Fei, et al. Dual channel short text intent recognition algorithm combining CNN and BiGRU[J]. *Computer Systems & Applications*, 2024, 33(5): 136-143. (in Chinese with English abstract)
- [39] CHEN J, WANG K. Short-time traffic flow prediction based on bayesian optimisation BiGRU-Attention model[C]// 世界交通运输大会. 世界交通运输大会论文集: 2024 年卷. 青岛: 人民交通出版社, 2024: 8.
- [40] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization[EB/OL]. (2019-12-03)[2024-07-09]. <https://arxiv.org/abs/1610.02391>.

Recognizing pig behavior using feature point detection

NI Pengfei¹, ZHOU Suyin¹, YE Junhua², XU Aijun^{1,3*}

(1. School of Mathematics and Computer Science, Zhejiang A & F University, Hangzhou 311300, China; 2. School of Environment and Resources, Zhejiang A & F University, Hangzhou 311300, China; 3. Zhejiang Key Laboratory of Intelligent Sensing and Robotics for Agriculture, Hangzhou 311300, China)

Abstract: Pig farming has been shifting towards the intensive and intelligent development in recent years, particularly with the advancements in artificial intelligence, deep learning and automation technologies. The machine vision and deep learning can be integrated to realize the non-invasive individual identification and behavior monitoring. It is crucial to determine the characteristic information that generated by pigs during daily activities. However, the existing extraction of pig feature has confined to the complex and inefficient recognition on the pig behavior, due to the frequent changes in pig posture. In this study, a feature points detection model (YOLO-ASF-P2) was proposed to extract the feature points in the key areas of the pig's body. Additionally, a pig behavior recognition model (CNN-BiGRU) was also introduced to combine the temporal information from the feature points. Firstly, the video and image data of pigs were collected by multi-angle cameras that deployed in the pig house. Two datasets were then formed for the pig feature point detection and behavior recognition. Traditional extraction of pig feature was often associated with the complex calculations, redundant feature information and low model robustness. Therefore, the original YOLOv8s-Pose model was improved to result in the YOLO-ASF-P2 model. The feature information of the P2 detection layer was utilized for the small targets. The attention scale sequence fusion (ASF) architecture was combined to focus on the key feature points of live pigs. The scale sequence feature fusion module (SSFF) was used the Gaussian kernel and nearest neighbor interpolation, in order to align the multi-scale feature maps of different downsampling rates (such as P2, P3, P4, and P5 detection layers). The same resolution was obtained as the high-resolution feature map. The triple feature encoding (TFE) module was used to capture the local fine details of small targets, and then fuse the local and global feature information. The channel and position attention mechanism module (CPAM) was used to capture and refine the spatial positioning information related to small targets. The important feature was effectively extracted from the feature map in different channels. The positioning accuracy of the model was also improved. The CNN-BiGRU model was used to recognize the pig behavior. The bidirectional gated recurrent unit (BiGRU) units were also utilized to capture the forward and backward information of sequence data in a bidirectional manner. The output was then weighted using the attention mechanism module (AttentionBlock). The excellent and stable performance was achieved in the self-built dataset. The average recognition accuracy of the model reached 96% for the three behaviors of sitting, standing, and lying. Specifically, the detection accuracy of YOLO-ASF-P2 reached 92.5%, the recall rate was 90%, the average precision (AP_{50-95}) was 68.2%, the parameter volume was only 18.4 M, and the performance was 39.6 G. These values were 1.1%, 2.3%, 1.5%, and 32.9% higher than those of the original model, respectively, where the model parameter volume was reduced by 17.5%. The average precision (AP_{50-95}) and accuracy of YOLO-ASF-P2 were improved by 17.4% and 2.9%, respectively, compared with the MMPose. While almost the same level of recall was maintained to enhance the performance of detection. The YOLO-ASF-P2 was improved the accuracy, recall rate and average precision (AP_{50-95}) with the reduced number of parameters, compared with the RTMPose. The similar accuracy was achieved, compared with the YOLOv5s-Pose. Both the recall rate and average precision (AP_{50-95}) were improved, compared with the YOLOv5s-Pose and YOLOv7s-Pose. The slightly lower accuracy was also observed, compared with the YOLOv7s-Pose. The lightweight model was achieved in the better performance to recognize the pig feature points. The CNN-BiGRU model of pig behavior also shared the high average recognition accuracy and stable performance. The parameter volume was 0.151 M, and the performance was 27.1 G. In summary, the integrated YOLO-ASF-P2 and CNN-BiGRU models were significantly improved the accuracy and robustness of pig feature point detection and behavior recognition. The finding can also offer the valuable tools for the intensive and intelligent development of pig farming.

Keywords: feature point detection; pig behavior; deep learning; time series; YOLOv8sPose; BiGRU